

Deep Learning

4A – IABD - ESGI

Me contacter

- pro@nicolasvidal.fr
- Discord: NicolasVidal#2440

Softmax et Categorical Cross Entropy

SGD

Règle de mise à jour des variables du modèle :

$$w_{t+1} = w_t - \alpha \frac{\partial loss}{\partial w_t}$$

Avec :

w_t est une variable (poids, biais, ...) du modèle à l'iteration t

w_{t+1} est la même variable mise à jour à l'iteration $t + 1$

α est le pas d'apprentissage

$\frac{\partial loss}{\partial w_t}$ est la dérivée de la fonction de loss (perte) par rapport à la variable considérée

SGD + momentum classique

Règle de mise à jour des variables du modèle :

$$v_{t+1} = \gamma v_t - \alpha \frac{\partial loss}{\partial w_t}$$
$$w_{t+1} = w_t + v_{t+1}$$

Avec :

w_t est une variable (poids, biais, ...) du modèle à l'iteration t

w_{t+1} est la même variable mise à jour à l'iteration $t + 1$

α est le pas d'apprentissage

$\frac{\partial loss}{\partial w_t}$ est la dérivée de la fonction de loss (perte) par rapport à la variable considérée

v_t est la vitesse (l'élan) de la variable à l'iteration t

v_{t+1} est la vitesse (l'élan) de la variable à l'iteration $t + 1$

γ est un facteur d'attenuation (la valeur du momentum), souvent réglé entre 0.5 et 0.99

SGD + EMA momentum

Règle de mise à jour des variables du modèle :

$$v_{t+1} = \gamma v_t + (1 - \gamma) \frac{\partial loss}{\partial w_t}$$
$$w_{t+1} = w_t - \alpha v_{t+1}$$

Avec :

w_t est une variable (poids, biais, ...) du modèle à l'iteration t

w_{t+1} est la même variable mise à jour à l'iteration $t + 1$

α est le pas d'apprentissage

$\frac{\partial loss}{\partial w_t}$ est la dérivée de la fonction de loss (perte) par rapport à la variable considérée

v_t est la moyenne mobile (roulante) exponentielle de la dérivée à la date t

v_{t+1} est la moyenne mobile (roulante) exponentielle de la dérivée à la date $t+1$

γ (on utilise aussi le symbole β de temps à autre) est un facteur d'attenuation (la valeur du momentum), souvent réglé entre 0.9 et 0.99

RMSPProp

Règle de mise à jour des variables du modèle :

$$s_{t+1} = \gamma s_t + (1 - \gamma) \left(\frac{\partial loss}{\partial w_t} \right)^2$$

$$w_{t+1} = w_t - \frac{\alpha}{\sqrt{s_{t+1} + \epsilon}} \times \frac{\partial loss}{\partial w_t}$$

Avec :

w_t est une variable (poids, biais, ...) du modèle à l'iteration t

w_{t+1} est la même variable mise à jour à l'iteration $t + 1$

α est le pas d'apprentissage

$\frac{\partial loss}{\partial w_t}$ est la dérivée de la fonction de loss (perte) par rapport à la variable considérée

s_t est la moyenne mobile (roulante) exponentielle du carré de la dérivée à la date t

s_{t+1} est la moyenne mobile (roulante) exponentielle du carré de la dérivée à la date $t+1$

γ (on utilise aussi le symbole β de temps à autre) est un facteur d'attenuation (aussié appelé décomposition), souvent réglé entre 0.9 et 0.99

ϵ est une petite valeur pour éviter la division par 0

Adam (sans correction du biais de l'EMA)

Règle de mise à jour des variables du modèle :

$$v_{t+1} = \gamma_1 v_t + (1 - \gamma_1) \frac{\partial loss}{\partial w_t}$$

$$s_{t+1} = \gamma_2 s_t + (1 - \gamma_2) \left(\frac{\partial loss}{\partial w_t} \right)^2$$

$$w_{t+1} = w_t - \frac{\alpha}{\sqrt{s_{t+1} + \epsilon}} \times v_{t+1}$$

Avec :

w_t est une variable (poids, biais, ...) du modèle à l'iteration t

w_{t+1} est la même variable mise à jour à l'iteration $t + 1$

α est le pas d'apprentissage

$\frac{\partial loss}{\partial w_t}$ est la dérivée de la fonction de loss (perte) par rapport à la variable considérée

v_t est la moyenne mobile (roulante) exponentielle de la dérivée à la date t

v_{t+1} est la moyenne mobile (roulante) exponentielle de la dérivée à la date $t + 1$

s_t est la moyenne mobile (roulante) exponentielle du carré de la dérivée à la date t

s_{t+1} est la moyenne mobile (roulante) exponentielle du carré de la dérivée à la date $t + 1$

γ_1 (on utilise aussi le symbole β_1 de temps à autre) est un facteur d'atténuation (aussi appelé de décomposition), souvent réglé à 0.9

γ_2 (on utilise aussi le symbole β_2 de temps à autre) est un facteur d'atténuation (aussi appelé de décomposition), souvent réglé à 0.999

ϵ est une petite valeur pour éviter la division par 0

Adam (avec correction du biais de l'EMA)

Règle de mise à jour des variables du modèle :

$$v_{t+1} = \gamma_1 v_t + (1 - \gamma_1) \frac{\partial loss}{\partial w_t} \qquad \hat{v}_{t+1} = \frac{v_{t+1}}{1 - \gamma_1^{t+1}}$$

$$s_{t+1} = \gamma_2 s_t + (1 - \gamma_2) \left(\frac{\partial loss}{\partial w_t} \right)^2 \qquad \hat{s}_{t+1} = \frac{s_{t+1}}{1 - \gamma_2^{t+1}}$$

$$w_{t+1} = w_t - \frac{\alpha}{\sqrt{\hat{s}_{t+1} + \epsilon}} \times \hat{v}_{t+1}$$

Avec :

w_t est une variable (poids, biais, ...) du modèle à l'iteration t

w_{t+1} est la même variable mise à jour à l'iteration $t + 1$

α est le pas d'apprentissage

$\frac{\partial loss}{\partial w_t}$ est la dérivée de la fonction de loss (perte) par rapport à la variable considérée

v_t est la moyenne mobile (roulante) exponentielle de la dérivée à la date t

v_{t+1} est la moyenne mobile (roulante) exponentielle de la dérivée à la date $t + 1$

s_t est la moyenne mobile (roulante) exponentielle du carré de la dérivée à la date t

s_{t+1} est la moyenne mobile (roulante) exponentielle du carré de la dérivée à la date $t + 1$

γ_1 (on utilise aussi le symbole β_1 de temps à autre) est un facteur d'atténuation (aussi appelé de décomposition), souvent réglé à 0.9

γ_2 (on utilise aussi le symbole β_2 de temps à autre) est un facteur d'atténuation (aussi appelé de décomposition), souvent réglé à 0.999

ϵ est une petite valeur pour éviter la division par 0

Convolutional Neural Networks

Convolutional Neural Networks

Pourquoi les PMC ne sont pas suffisants ?

Convolutional Neural Networks

Pourquoi les PMC ne sont pas suffisants ?

=> Problématique des inputs de grandes dimensions

Convolutional Neural Networks

Pourquoi les PMC ne sont pas suffisants ?

⇒ Problématique des inputs de grandes dimensions

Admettons une image en 4k (3840x2160) au format RGB en entrée d'un PMC

Explosion du nombre de paramètres !

Convolutional Neural Networks

Pourquoi les PMC ne sont pas suffisants ?

⇒ Problématique des inputs de grandes dimensions

Admettons une image en 4k (3840x2160) au format RGB en entrée d'un PMC

Explosion du nombre de paramètres !

Au minimum (sans couche cachée et avec 1 seul neurone en sortie) :

$(3840 \times 2160 \times 3 + 1) = 24\,883\,201$ poids !

Convolutional Neural Networks

Pourquoi les PMC ne sont pas suffisants ?

⇒ Problématique des inputs de grandes dimensions

Au minimum (sans couche cachée et avec 1 seul neurone en sortie) :

$(3840 \times 2160 \times 3 + 1) = 24\,883\,201$ poids !

Problème d'espace mémoire : 100Mo

Avec une couche cachée de 100 neurones :

$(3840 \times 2160 \times 3 \times 100 + 100 + 100 + 1) = 2\,488\,320\,201$ poids

Problème d'espace mémoire : à peu près 10Go de ram en fp32

Convolutional Neural Networks

Pourquoi les PMC ne sont pas suffisants ?

⇒ Problématique des inputs de grandes dimensions

En plus, très mauvais signe pour la qualité de généralisation (rapport taille dataset / nombre de paramètres du modèle)

Convolutional Neural Networks

Et si nous réutilisions des poids ?

Convolutional Neural Networks

Et si nous réutilisons des poids ?

=> Comment ?

Convolutional Neural Networks

Notion de filtres

=> Démonstration sur Excel !

Convolutional Neural Networks

Exercice :

- Créez votre propre fonction :
 MyOwnConv(filtre, image) -> image filtrée
- Créez un dataset rapidement de quelques images en niveau de gris
- Appliquez un filtre choisi par vous (EdgeDetect par exemple) et sauvegardez les images filtrées dans un autre dossier
- Entraînez un modèle Tensorflow composé d'une seule couche de type Conv2D (sans biais !) à prédire les images filtrées à partir des images de départ
- Affichez les valeurs des poids du modèle entraîné

Vous devriez retomber sur les valeurs de votre filtre choisi

Convolutional Neural Networks

- Problème de la dernière couche d'un modèle composé uniquement de couches de convolution

Convolutional Neural Networks

- Problème de la dernière couche d'un modèle composé uniquement de couches de convolution
 - Proposition d'utilisation de couches de Pooling