

1. Fonction `process_file`

Cette fonction traite un fichier Parquet individuel pour en extraire des informations utiles.

Étapes :

1. Chargement du fichier :

- Le fichier Parquet est chargé sous forme de DataFrame avec `pd.read_parquet(file_path)`.

2. Suppression de la colonne inutile (step) :

- Si la colonne `step` est présente, elle est supprimée car elle est jugée non pertinente.

3. Extraction des statistiques descriptives :

- La méthode `.describe()` est utilisée pour calculer des statistiques descriptives (comme la moyenne, l'écart-type, les valeurs minimales/maximales, etc.).
- Ces statistiques sont converties en un tableau à une dimension avec `.values.reshape(-1)`.

4. Extraction de l'identifiant (id) :

- L'identifiant unique de la série temporelle est extrait du chemin du fichier à l'aide de `os.path.basename` et d'un découpage sur le caractère `=`.

Retour :

- **stats** : Les statistiques descriptives calculées à partir des données de la série temporelle.
 - **id_value** : L'identifiant unique associé au fichier.
-

2. Fonction `load_time_series`

Cette fonction traite un répertoire entier contenant plusieurs fichiers Parquet pour regrouper leurs caractéristiques dans un tableau.

Étapes :

1. Lister les sous-dossiers :

- La liste des répertoires (ou des IDs) dans le dossier principal est obtenue avec `os.listdir(directory)`.

2. Boucle sur les sous-dossiers :

- Pour chaque ID, le fichier part-0.parquet est recherché dans le sous-dossier correspondant.

3. Traitement des fichiers :

- Si le fichier existe, la fonction `process_file` est appelée pour en extraire les statistiques et l'ID.

4. Construction du DataFrame final :

- Les statistiques extraites sont regroupées dans un tableau (`all_stats`).
- Les IDs correspondants sont stockés dans une liste (`all_ids`).
- Un DataFrame est créé avec les IDs comme première colonne, suivi des statistiques descriptives. Les colonnes des statistiques sont nommées dynamiquement (`TS_Feature_0`, `TS_Feature_1`, etc.).

Retour :

- **df** : Un DataFrame contenant les IDs et leurs caractéristiques statistiques

1^{er} Model linéaire avec keras :

The screenshot shows the Kaggle website interface for the 'Child Mind Institute — Problematic Internet Use' competition. The leaderboard is displayed, showing the top participants. The top participant is Michael Kamal 92 with a score of 0.171. A pop-up message says 'Your First Entry! Welcome to the leaderboard!'.

Rank	Participant	Score	Submissions	Time
934	Michael Kamal 92	0.171	3	5d
935	Dmitriy Guler	0.169	1	12d
936	Ahmed Suliman	0.167	2	2d
937	a big world	0.164	2	3d
938	Pierpaolotex	0.138	2	5d
939	nabil sarker	0.127	1	1m
940	Somnath Banerjee	0.127	11	2d

2ème Model MLP avec keras :

Configuration :

Nb couches : 4

Nb neurones : [128, 64, 32, 4]

Fonction d'activation : tanh

Fonction d'activation pour couche sortie : Softmax

Algorithme d'apprentissage : SGD

Learning rate : 0.01

Epochs : 100

Batch size : 32

Loss function : categorical_crossentropy

Metrics : categorical_accuracy

kaggle.com/competitions/child-mind-institute-problematic-internet-use/leaderboard